

TramFlow

Нагрузочное тестирование API

Итоговый отчёт · 3 октября 2026

400 RPS в течение 45 минут

1 080 000 успешных запросов · p95 9,15 мс · p99 16,98 мс

Длительный смешанный прогон завершился в пределах заданных критериев: из 1 080 001 бизнес-запроса один не прошёл проверку, пропущенных итераций нет. Это подтверждённая рабочая точка данного стенда, а не универсальный предел производительности. [R18]

Проверка	Результат	Интерпретация
Soak · 400 RPS	PASS · 45 мин	Длительная рабочая точка
Mixed · 500 RPS	PASS · 3 мин	Максимальная прошедшая короткая точка
Mixed · 600 RPS	FAIL · 180 ошибок	Превышен порог ошибок

Главные выводы

В коротком тесте одна API-реплика выдержала 500 RPS без ошибок. На 600 RPS темп запросов сохранялся, но 180 запросов не прошли проверку: доля ошибок 0,1667% превысила лимит 0,1%. Отказ произошёл по критерию ошибок, а не по порогу p95. [R14–R15]

Во время soak память API оставалась в узком диапазоне по Docker working set. Одновременно память генератора kb росла; это отдельное ограничение тестовой инфраструктуры. Тесты с двумя API-репликами не подтверждают выигрыш от масштабирования: ресурсы показывают выраженный перекос нагрузки. [R16–R18]

Область применимости: `synthetic_mock`, прогретый кэш и тестовый `snapshot`. Результаты характеризуют обслуживание HTTP-запросов, но не скорость обученной ONNX-модели, качество прогнозов или поведение `production`-данных. [R02–R18]

Основание отчёта: 18 прогонов, в том числе 17 нагрузочных и один функциональный login; 26 скриншотов Grafana. Для нагрузочных прогонов проверены согласованность счётчиков, ошибок, задержек и ресурсных выборок между JSON и CSV. Реестр источников приведён в конце отчёта.

1. Стенд и границы измерений

Измеренные ограничения контейнеров

Лимиты ниже извлечены из system.csv. Они описывают квоты контейнеров, а не физические характеристики машины. В прогонах с двумя репликами лимит API применяется к каждой реплике отдельно. [R02–R18]

Компонент	CPU, ядер	Лимит RAM
API, каждая реплика	2	2 GiB
PostgreSQL	2	1 GiB
k6	2	2 GiB
Gateway	1	128 MiB
Prometheus	1	512 MiB
Grafana	Без CPU-квоты	384 MiB
postgres-exporter	Без CPU-квоты	128 MiB

CPU в процентах квоты рассчитывается как Docker CPU% / число выделенных CPU. Например, 25,97% квоты API в soak соответствует примерно 0,52 занятого ядра из двух. Показатели CPU без установленной квоты не представлены как «процент лимита». [R18]

Данные и версия приложения

Для всех 17 нагрузочных отчётов указан runtime_mode **synthetic_mock**, модель **synthetic-stress-256-v1** и snapshot **stress-october-2026-v1**. В активных forecast-прогонах рассчитанный cache hit ratio равен 1,0. Это тест прогретого пути обслуживания, а не постоянной генерации новых предсказаний. [R02–R18]

Во всех этих отчётах записан commit **b5602c89aca60ec09b6b6acc377935b346ebfccf** и dirty working tree. У коротких тестов и soak разные source SHA-256. Поэтому soak является отдельным измерением изменённого рабочего дерева; полностью идентичная сборка между сериями не установлена. Точные хэши — в разделе 14. [R02–R18]

Что ограничивает переносимость результатов

Схема runner размещает k6, API, PostgreSQL и мониторинг на одном Docker-хосте. Изолированный удалённый генератор не использовался в этой схеме. Модель CPU, физическая RAM, версии ядра и Docker, закреплённые image digests не зафиксированы в экспортированном наборе: environment.json в нём отсутствует. Контейнерные квоты не заменяют эти сведения. [C1; R02–R18]

Измеряется HTTP-путь через gateway; это не браузерный end-to-end тест. Латентность интерфейса, внешней сети, публичного TLS и пользовательского устройства в опубликованные p95/p99 не входит. [C1–C2]

2. Методика и критерии приёма

Профиль нагрузки

Основные сценарии используют constant-arrival-rate: k6 планирует фиксированное число итераций в секунду независимо от времени ответа. В реализации проекта одна измеряемая итерация выполняет один бизнес-запрос. Аутентификация, подготовка и warmup исключены из бизнес-процентилей; повторных попыток в бизнес-операции нет. [C2; D1]

Отдельные endpoint-тесты выполнены на 50 RPS: bootstrap, geometry и summary — по 2 минуты после 30 секунд warmup; day, week, month и scenario — по 3 минуты после минуты warmup. Mixed sweep и тесты двух реплик — 3 минуты измерения и 1 минута warmup. Soak — 45 минут и 2 минуты warmup. Между warmup и измерением runner k6 задаёт 15-секундный интервал завершения прогрева. [R02–R18; C2]

Состав mixed workload по фактическим счётчикам: day — около 60%; scenario — 15%; bootstrap, routes и geometry — по 5%; month и export — по 3%; week и summary — по 2%. Это фиксированная тестовая смесь, не статистика реального пользовательского трафика. [R09–R18]

Критерий measurement	Условие
Общая и endpoint-доля бизнес-ошибок	< 0,1%
Успешность проверок checks	> 99,9%
Общий и endpoint HTTP p95	< 250 мс
HTTP p95 прогноза day	< 200 мс
Полная клиентская длительность p95	< 300 мс
Dropped iterations	0
Число выполненных итераций	Не меньше rate × duration – 1

Как читать показатели

RPS в таблицах — успешные бизнес-запросы, делённые на интервал от первого старта до последнего завершения в measurement. Отклонения на сотые RPS и один дополнительный запрос связаны с фактическими границами окна; они не означают отдельного прироста мощности. [R02–R18]

p50/p95/p99 берутся из business_latency{phase:measurement}: это клиентская HTTP-длительность. Полная клиентская длительность отдельно хранится в business_client_wall. Общие http_reqs и http_req_failed охватывают также другие фазы, поэтому не смешиваются с результатами measurement. [C2; D2]

Ошибка означает провал HTTP-статуса или проверки контракта ответа. Dropped iterations — не отправленные итерации, а не HTTP-ошибки; нулевое значение не доказывает, что у генератора нет ресурсных ограничений. [C2; D3]

3. Сравнение отдельных операций

Все строки таблицы ниже относятся к нагрузке 50 RPS и одной API-реплике. Во всех семи прогонах бизнес-ошибки и dropped iterations равны нулю; выполнены все заданные thresholds. [R02–R08]

Операция	Окно	Запросы	p50, мс	p95, мс	p99, мс
bootstrap	2m	6 001	1,48	2,64	3,02
route-geometry	2m	6 000	1,22	2,43	2,70
forecast-day	3m	9 001	3,45	6,83	7,62
forecast-week	3m	9 001	4,73	9,94	11,20
forecast-month	3m	9 001	12,05	16,65	22,13
scenario	3m	9 001	3,76	5,24	6,00
summary	2m	6 001	3,92	4,55	5,40




Рисунок 1. Клиентский HTTP p95 отдельных операций при 50 RPS. Источники: R02–R08 / report.json.

Наиболее высокая p95 среди этих операций у forecast-month: 16,65 мс против 6,83 мс у forecast-day. Это сравнение конкретных тестовых выборок и прогретого кэша, не универсальная стоимость прогнозов на месяц и сутки. [R04–R06]

Login учитывается отдельно. Функциональный тест сделал 55 запросов без ошибок, примерно 0,454 запроса/с; p50 — 105,33 мс, p95 — 135,94 мс, p99 — 144,50 мс. Один VU и пауза между логинами не позволяют трактовать имя каталога «50rps» как измеренную пропускную способность авторизации. [R01; C2]

Отдельного завершённого export-прогона в наборе нет. Export проверен внутри mixed workload, в том числе 32 400 запросами в soak без ошибок. [R18]

4. Ступенчатая нагрузка: 50–600 RPS

Одна API-реплика; каждая точка — 3 минуты измерения после минуты прогрева. Процентили рассчитаны отдельно для каждой точки, не усреднены между прогонами. [R09–R15]

Цель, RPS	Успешные RPS	p95, мс	p99, мс	Ошибки	Итог
50	50,00	6,24	24,48	0	PASS
100	100,01	4,20	13,95	0	PASS
200	200,00	3,64	13,03	0	PASS
300	300,01	5,60	13,95	0	PASS
400	400,01	8,49	15,82	0	PASS
500	500,01	13,15	22,81	0	PASS
600	599,01	44,46	93,83	180	FAIL




Рисунок 2. p95 и p99 mixed workload по точкам нагрузки. Источники: R09–R15 / report.json.

500 RPS — максимальная прошедшая точка короткой серии. На ней обработано 90 000 запросов без ошибок, p95 — 13,15 мс, p99 — 22,81 мс. Это не доказательство устойчивости 500 RPS на часах или днях. [R14]

На 600 RPS p95 выросла примерно в 3,38 раза, p99 — в 4,11 раза относительно 500 RPS. При этом 599,01 успешного запроса/с и нулевые drops не компенсируют нарушение критерия ошибок. Результат этой точки — FAIL. [R14–R15]

Более низкие задержки некоторых точек 100–300 RPS по сравнению с 50 RPS не трактуются как ускорение от увеличения нагрузки: серия не содержит повторов, позволяющих отделить вариативность стенда от устойчивого эффекта. [R09–R12]

5. Что произошло на 600 RPS

Из 108 001 измеренного бизнес-запроса успешно завершились 107 821, не прошли проверку 180. Общая доля ошибок — **0,1667%**, выше порога **0,1%**. Нарушены общий и все endpoint-критерии ошибок, а также checks > 99,9%; критерии p95 и dropped iterations пройдены. Код завершения k6 — 99. [R15]

Операция	Запросы	Ошибки	Доля ошибок
day	64 801	115	0,1775%
scenario	16 200	23	0,1420%
bootstrap	5 400	6	0,1111%
routes	5 400	11	0,2037%
geometry	5 400	6	0,1111%
week	2 160	4	0,1852%
month	3 240	6	0,1852%
summary	2 160	3	0,1389%
export	3 240	6	0,1852%




Рисунок 3. CPU API и генератора в короткой серии: среднее и максимум выборок, в процентах квоты.

Источники: R09–R15 / system.csv.

На 600 RPS CPU API в среднем занимал 46,84% квоты, максимум — 65,78%; генератор — 67,52% и 92,08% соответственно. Это указывает на заметный ресурсный вклад k6, но не устанавливает единственную причину ошибок. [R15]

Без HTTP-статусов, текстов ошибок и backend.log нельзя приписать эти отказы rate limiting, БД, gateway или самому генератору. Корректный вывод: при 600 RPS стенд нарушил SLO по ошибкам; первопричина не локализована. [R15]

6. Длительный прогон: 400 RPS × 45 минут

Измерительное окно: **14:10:46,671–14:55:46,672 UTC** 3 октября 2026 года. Warmup 2 минуты не входит в 45 минут. В ресурсной выборке присутствует одна API-реплика, контейнер tramflow-api-3; суффикс «3» не означает три одновременно работающие реплики. [R18]

Показатель	Результат
Нагрузка / измерение / API-реплики	400 / 45 min / 1
Всего / успешно, запросов	1 080 001 / 1 080 000
Успешные запросы в секунду	399,9999
p50 / p95 / p99, мс	1,40 / 9,15 / 16,98
Ошибок / доля ошибок	1 / 0,0000926%
Dropped iterations / итог thresholds	0 / PASS

Результаты операций внутри soak

Операция	Запросы	p95, мс	p99, мс	Ошибки
day	648 001	6,03	13,38	0
scenario	162 000	5,59	13,51	1
bootstrap	54 000	4,37	14,49	0
routes	54 000	2,91	13,46	0
geometry	54 000	2,40	11,66	0
week	21 600	7,05	15,27	0
month	32 400	20,50	29,85	0
summary	21 600	3,18	10,72	0
export	32 400	4,51	18,23	0

Единственная бизнес-ошибка относится к scenario: 1 из 162 000 запросов этой операции. Все endpoint-пороги при этом соблюдены. Общая успешность measurement — **99,999907%**; формулировка «ноль ошибок за 45 минут» была бы неверной. [R18]

В общей метрике http_req_failed записано 7 неуспешных HTTP-запросов за весь запуск, но это другой охват фаз. Для итогов soak используется одна ошибка из measurement, а не смесь измерения с подготовкой и прогревом. Причина единичного отказа не классифицируется по агрегатам. [R18]

7. Soak: CPU и память API




Рисунок 4. CPU в течение measurement. Для читаемости показана скользящая медиана по 13 выборкам, примерно одной минуте; средние и максимумы в таблицах рассчитаны по исходным выборкам. Источник: R18 / system.csv.




Рисунок 5. Docker working set API: все 589 выборки измерительного окна без сглаживания. Источник: R18 / system.csv.

Средняя загрузка API — **25,97% CPU-квоты**, максимальная выборка — **39,15%**. Среднее за первые 5 минут — 26,24%, за последние 5 минут — 28,28%: небольшое повышение к концу есть, постоянного упора в квоту по этим выборкам нет. [R18]

Working set API в measurement — **34,34–40,55 MiB**. Средние значения первых и последних 5 минут — 37,05 и 37,49 MiB. Выявленного накопления этой памяти за 45 минут не видно. Это наблюдение не является доказательством отсутствия любых утечек при более длительной или другой нагрузке. [R18]

Отдельно измеренный process RSS: первая выборка 48,01 MiB, последняя 30,61 MiB, максимум 51,57 MiB. RSS и Docker working set — разные показатели, поэтому их нельзя подменять друг другом. В report.json зафиксирован нулевой process/cgroup swap. Отсутствие рестартов и OOM отдельно не подтверждается: final-state.json не включён в экспорт. [R18]

8. Soak: генератор и остальные ресурсы




Рисунок 6. Память k6 в measurement: от 150,5 до 733,6 MiB, максимум 782,7 MiB. Источник: R18 / system.csv.

Генератор прибавил **583,1 MiB** между первой и последней выборкой. Среднее за первые 5 минут — 189,76 MiB, за последние — 696,28 MiB. Это рост памяти k6, а не API; на данном 45-минутном интервале лимит 2 GiB ещё не достигнут. [R18]

В документации k6 для remote-write Trend → gauges отмечена высокая стоимость используемой структуры данных по памяти. Это возможный вклад в наблюдаемый рост, но по CSV нельзя доказать причинность или назвать рост утечкой. Для более длительного теста нужны профиль генератора и отдельное сравнение вариантов вывода метрик. [C1; D4]

Компонент	CPU квоты, ср. / макс., %	Working set, макс., MiB
API	25,97 / 39,15	40,55
PostgreSQL	15,22 / 23,39	91,02
Gateway	9,60 / 14,22	12,45
k6	35,84 / 70,34	782,70
Prometheus	1,20 / 11,68	107,70
Grafana	Квота не задана	135,20
postgres-exporter	Квота не задана	11,26

Средняя CPU-нагрузка k6 — 35,84% его квоты; максимум выборок — 70,34%. PostgreSQL — 15,22% и 23,39% соответственно. Вывод о запасе относится к контейнерным выборкам: он не исключает коротких пиков, ожиданий I/O или конкуренции за физические ресурсы хоста. [R18]

Практическое ограничение серии: последующие многочасовые soak нельзя автоматически считать эквивалентными, пока рост памяти генератора не объяснён и не проверен отдельно.

9. Одна и две API-реплики

Тесты двух реплик на 300 и 500 RPS прошли thresholds без ошибок и пропущенных итераций. Однако наличие двух контейнеров само по себе не доказывает распределение нагрузки. [R16–R17]

RPS	API	Успешные RPS	p95, мс	p99, мс	Ошибки
300	1	300,01	5,60	13,95	0
300	2	300,00	6,84	15,24	0
500	1	500,01	13,15	22,81	0
500	2	500,01	15,73	33,47	0




Рисунок 7. Средняя CPU-нагрузка каждой API-реплики в двухрепличных прогонах. Источники: R16–R17 / report.json и system.csv.

На 500 RPS api-1 занимала в среднем **36,78%** своей CPU-квоты, api-2 — **0,485%**. Вторая реплика также не имеет наблюдений для cache hit ratio и storage p95 в runtime_samples. Скриншот Grafana согласуется с этим перекосом: одна CPU-линия активна, другая близка к нулю. [R17; G3]

Ускорение и эффективность горизонтального масштабирования не установлены. В этих двух точках p95/p99 с двумя репликами не ниже, чем с одной. Нельзя объяснить это недостатком архитектуры до проверки фактической маршрутизации запросов. [R12; R14; R16–R17]

Следующий проверочный шаг — сопоставить RPS каждой реплики, убедиться, что gateway видит обе, и повторить одинаковые точки. CPU — косвенный индикатор перекоса, а не точный счётчик распределённых запросов. Успех проверки межрепличных сессий этой серией также не подтверждается.

10. Grafana: поведение soak во времени



Рисунок 8. Исходный скриншот soak, верхние два ряда панелей. Диапазон на экране: 17:07:02–17:56:53; отображаемые часы сдвинуты на +3 часа относительно UTC артефактов. Источник: G1, Pasted image.png.

Графики RPS визуально показывают плато около 400 запросов/с. К концу периода заметны локальное повышение server-side p95 и краткий всплеск ошибок. Поэтому результат описывается как прохождение 45-минутного SLO с единичным отказом, а не как абсолютно ровные задержки и нулевая ошибочность. [R18; G1]



Рисунок 9. Увеличенный временной диапазон конца soak, исходные панели. Источник: G1, Pasted image (5).png.

Точные итоговые p95 9,15 мс и p99 16,98 мс получены из k6-summary.json, а не считаны с верхних панелей. Конфигурация этих панелей содержит особенности агрегации, описанные в следующем разделе. Их кривые не используются для вычисления итоговых процентилей. [R18; C3]

Падение RPS после конца измерительного окна ожидаемо при завершении нагрузки. Изменения внутри окна требуют отличать от завершения теста по точным timestamp. Скриншоты сохраняются как визуальное свидетельство, а не замена исходным числовым артефактам.

11. Ограничения текущего dashboard



Рисунок 10. Общий скриншот mixed workload, Last 30 minutes и test run = All. Он объединяет несколько ступеней, а не представляет один run. Источник: G2.

Какие панели нельзя читать как итоговые метрики

В переданном dashboard JSON панели «k6 client p95/p99» используют `avg(...)` от уже рассчитанных процентилей HTTP-серий. Среднее процентилей разных серий не равно процентилю объединённой выборки. Поэтому сравнение нагрузки и headline-числа в отчёте строятся по итоговому `business_latency measurement`, а не по среднему на dashboard. [C3; D4–D5]

Панель «k6 semantic failure ratio» аналогично усредняет rates. При разных объёмах запросов по endpoint это не взвешенная общая доля ошибок. Панель «achieved business RPS» считает `business_requests_total`, то есть все измеренные запросы, а не только успешные. [C3]

На скриншотах выбран test run = All. В таком режиме рядом могут отображаться данные нескольких запусков. Серверные панели в этой конфигурации не фильтруются по `testid`, поэтому один выбор run не изолирует серверные метрики от остальной нагрузки. [G1–G3; C3]

Ресурсные панели

CPU/RSS включают также `postgres-exporter`; его линию нельзя записывать в ресурсы API. Выражения с оператором `or` для RSS/heap, DB pool и swap могут скрывать серии с совпадающими наборами меток: это объединение множеств, не команда «показать оба показателя». «No data» у ONNX означает отсутствие наблюдений, а не 0 мс inference. [C3; D6]

Для следующей версии dashboard нужны отдельные запросы для ресурсов, явные job/instance-фильтры, корректные взвешенные счётчики ошибок и агрегация задержек через совместимые гистограммы. Изменение dashboard не требует пересчёта уже сохранённых корректных итоговых k6-summary. [D5–D6]

12. Выводы и дальнейшая проверка

Подтверждённый результат

На `synthetic_mock snapshot` одна API-реплика с лимитами 2 CPU и 2 GiB выдержала `mixed workload` 400 RPS в течение 45 минут после двухминутного прогрева. Успешно обработано 1 080 000 из 1 080 001 бизнес-запроса; p95 составила 9,15 мс, p99 — 16,98 мс, `dropped iterations` — 0. Все заданные `thresholds` пройдены. [R18]

В короткой трёхминутной серии максимальная прошедшая точка — 500 RPS; при 600 RPS нарушен критерий ошибок. Это два разных уровня доказательности: 400 RPS проверены длительно, 500 RPS — коротким прогоном. 450 RPS отдельно не измерялись. [R09–R18]

Что нельзя выводиться из этой серии

Результаты не доказывают пропускную способность реальной ML-модели, качество прогноза, отсутствие утечек на произвольном горизонте, выигрыш двух реплик или конкретную причину отказов на 600 RPS. Средние ресурсы не исключают коротких пиков; `source hash` между короткой серией и `soak` изменился. [R02–R18]

№	Проверка	Что она установит
1	Разобрать 180 ошибок на 600 RPS	Статусы и первопричину отказов
2	Проверить RPS каждой API-реплики	Фактическую балансировку
3	Исправить агрегации Grafana	Корректность визуальных KPI
4	Повторить 400/500 RPS на фиксированной сборке	Воспроизводимость и разброс
5	Испытать реальные модели и новые выборки	Работу без 100% <code>cache hit</code>

Дополнительные сценарии

`Cold start`, `scale consistency check`, `Go microbenchmarks` и отдельный `export` не имеют завершённых артефактов в этом экспорте. Они не обозначаются как `PASS` и не входят в численные итоги. `Login` является отдельным функциональным подтверждением; `export` имеет подтверждение только внутри `mixed workload`. [R01–R18]

Повторный полный `sweeper` не нужен для оформления уже выполненных измерений. Дальнейшие прогоны следует направить на перечисленные пробелы, сохраняя этот набор как самостоятельную версию результатов.

13. Реестр прогонов

Все идентификаторы относятся к 3 октября 2026 года. Пути исходных файлов имеют вид `bench_export/benchmarks/results/<run_id>/`. В каждом каталоге доступны `benchmark.md`, `report.json`, `k6-summary.json` и `system.csv`. Метка **PASS** означает прохождение заданных `thresholds`; для `login` — функциональный успех.

Код	Run ID	Окно / API	Итог
R01	20261003T115101Z-login-50rps-410549	login	PASS
R02	20261003T115646Z-bootstrap-50rps-245729	2m / 1 API	PASS
R03	20261003T120230Z-route-geometry-50rps-43819	2m / 1 API	PASS
R04	20261003T120656Z-forecast-day-50rps-967048	3m / 1 API	PASS
R05	20261003T121315Z-forecast-week-50rps-222329	3m / 1 API	PASS
R06	20261003T121952Z-forecast-month-50rps-192319	3m / 1 API	PASS
R07	20261003T122630Z-scenario-50rps-812845	3m / 1 API	PASS
R08	20261003T123310Z-summary-50rps-813420	2m / 1 API	PASS
R09	20261003T125735Z-mixed-workload-50rps-609940	3m / 1 API	PASS
R10	20261003T130200Z-mixed-workload-100rps-158780	3m / 1 API	PASS
R11	20261003T130631Z-mixed-workload-200rps-833642	3m / 1 API	PASS
R12	20261003T131057Z-mixed-workload-300rps-405847	3m / 1 API	PASS
R13	20261003T131528Z-mixed-workload-400rps-464926	3m / 1 API	PASS
R14	20261003T132003Z-mixed-workload-500rps-361500	3m / 1 API	PASS
R15	20261003T132428Z-mixed-workload-600rps-789005	3m / 1 API	FAIL
R16	20261003T134555Z-mixed-workload-300rps-385818	3m / 2 API	PASS
R17	20261003T135019Z-mixed-workload-500rps-665159	3m / 2 API	PASS
R18	20261003T140829Z-mixed-workload-400rps-208599	45m / 1 API	PASS

Набор содержит 1 665 014 измеренных бизнес-запросов в 17 нагрузочных прогонах и 181 бизнес-ошибку, из которых 180 относятся к R15 и одна — к R18. Login: ещё 55 отдельных функциональных запросов. Сводная успешность всех запусков не используется как SLO: смешивать разные нагрузки и длительности для этой цели некорректно.

Программная сверка 17 нагрузочных `report.json` с `k6-summary.json` и `measurement`-выборками `system.csv` не выявила расхождений в проверенных счётчиках, длительностях, задержках, числе ресурсных выборок и среднем `working set`. Результат сверки включён в `analysis.json`.

14. Источники и воспроизводимость

Артефакты измерений

R01–R18 — каталоги прогонов из реестра. report.json используется для итоговых значений; k6-summary.json — для thresholds, endpoint-счётчиков и границ measurement; system.csv — для ресурсов и графиков; benchmark.md — для provenance и source hash.

G1 — benches/soak/: шесть скриншотов, в том числе Pasted image.png и Pasted image (5).png. **G2** — benches/mixed_workload/: два скриншота. **G3** — benches/2_replicas/: Screenshot from 2026-10-03 16-54-51.png и 16-54-57.png. Остальные 16 скриншотов относятся к login, bootstrap, geometry, forecast day/week/month, scenario и summary. Всего 26; каталог export пуст.

C1 — MT_hack-observability-grafana.zip: scripts/benchmark.py, scripts/report.py, compose.yaml. **C2** — тот же проект: loadtest/lib/runner.js, selection.mjs и login.js. **C3** — deploy/grafana/dashboards/tramflow.json. Код используется для объяснения методики и конфигурации; фактические результаты берутся из R01–R18.

Идентичность исходников

Commit короткой серии и soak: b5602c89aca60ec09b6b6acc377935b346ebfccf; dirty = True.

Source SHA-256 короткой серии R02–R17:

```
7c8338cad064156eae1e29c323d1349e882ee04cc76d2f38823f0f65b1de0b41
```

Source SHA-256 soak R18:

```
85a065a438b221dcc5152db2d2c7fdc5431954ae094f24a5915a5ca8b30412b8
```

Точные route_ids, route_count, host metadata и image digests должны сопровождать следующую публикацию в environment.json. Для диагностики ошибок нужны также backend.log и сырые события; для рестартов — final-state.json; для пересчёта серверных временных рядов — metrics.ndjson либо выгрузка Prometheus. Эти файлы не входят в компактный экспорт.

Методические источники

D1. Grafana k6 - Constant arrival rate

D2. Grafana k6 - Built-in metrics

D3. Grafana k6 - Dropped iterations

D4. Grafana k6 - Prometheus remote write

D5. Prometheus - Histograms and summaries

D6. Prometheus - Operators

Все таблицы и новые графики рассчитаны из числовых артефактов; скриншоты обрезаны только для увеличения читаемости. Кривые латентности по времени из агрегированных summary не реконструировались. Неизмеренные показатели не заменялись нулями.